Estadística Descriptiva

Apunts esquemàtics · Grau en Enginyeria Química · Curs 2025-26

Basats en la presentació de l'assignatura, ampliats amb explicacions, exemples resolts i un formulari final

1. Conceptes bàsics: població, mostra, variables
2. Variables qualitatives: freqüències, taules i gràfics
3. Variables quantitatives discretes
4. Variables contínues: histogrames
5. Mesures de tendència central
6. Mesures de dispersió i de posició
7. Diagrames de caixa (box-plot)
8. La distribució normal
9. Dues variables: covariància, correlació i regressió
10. Resum d'R
11. Formulari
12. Annex: valoració de la presentació i errades detectades

1 · Conceptes bàsics

Estadística descriptiva: conjunt de tècniques per **organitzar, resumir i representar** les dades. No treu conclusions més enllà de les dades observades (això és la *inferència*, que es veurà al final del curs).

- **Població**: *tot* el conjunt d'individus/objectes/fets que volem estudiar.
  Ex.: tots els lots de producció d'un reactor.
- **Mostra**: *subconjunt* de la població que realment observem (mida n).
  Ex.: 35 lectures de cadmi a l'aire.
- **Individu / cas**: cada element de la mostra (una fila de la matriu de dades).
- **Variable**: característica que mesurem a cada individu (una columna).

Per què una mostra? Estudiar tota la població sol ser impossible, car o destructiu (p. ex. assajos de ruptura). La mostra ha de ser **representativa** (idealment aleatòria) perquè els resultats siguin extrapolables.

Paràmetre vs estadístic: un valor de la *població* (μ, σ) és un **paràmetre**; el mateix calculat a la *mostra* ($\bar{x}, s$) és un **estadístic**.

Tipus de variables

Tipus	Subtipus	Què vol dir	Exemples
Qualitativa (categòrica)	Nominal	Etiquetes sense ordre	gènere, comarca, color, marca
	Ordinal	Categories amb ordre natural	fred < tebi < calent; nivell d'estudis
Quantitativa (numèrica)	Discreta	Valors aïllats (es *compten*)	nombre de fills, edat en anys, peces defectuoses
	Contínua	Qualsevol valor d'un interval (es *mesuren*)	temperatura, pressió, pes, concentració

Compte! Que una variable qualitativa es codifiqui amb números (p. ex. 1 = home, 2 = dona) **no** la fa quantitativa: calcular-ne la mitjana no té sentit. Pregunta clau: *té sentit sumar o restar els valors?*

Matriu de dades

	Gen	Edat	Pes	Alc	Nota	Comarca
1	M	19	75.0	1.75	3.36	Barcelonès
2	M	18	65.0	1.80	6.40	Maresme
3	F	19	51.0	1.54	5.50	Barcelonès
4	F	20	45.0	1.55	7.90	Osona
5	F	18	53.0	1.71	5.30	Vallès Occ.
6	F	18	58.0	1.72	8.70	Barcelonès
7	F	18	65.0	1.63	6.80	Vallès Or.
8	F	18	53.0	1.70	5.20	Baix Llobregat
9	F	20	76.0	1.65	3.30	Osona
10	M	18	65.0	1.73	5.80	Vallès Or.
11	F	20	60.0	1.75	2.90	Baix Penedès
12	F	18	50.0	1.65	7.00	Baix Ebre
13	F	18	57.5	1.65	7.50	Barcelonès
14	F	19	47.0	1.62	6.70	Baix Llobregat

Showing 1 to 14 of 76 entries, 6 total columns

Matriu de dades de la presentació (76 estudiants).

- **Files** = casos (individus). **Columnes** = variables.
- Nombre de files = mida de la mostra n (aquí $n = 76$).

Resposta a «Quin tipus de variables apareixen?»

- **Gen**: qualitativa nominal
- **Comarca**: qualitativa nominal
- **Edat**: quantitativa discreta (en anys sencers)
- **Pes, Alc**: quantitatives contínues
- **Nota**: quantitativa contínua (en la pràctica, discreta amb dos decimals)

2 · Variables qualitatives

Freqüències

Variable C amb modalitats $C_1, \dots, C_k$, mostra de mida n:

Freqüència absoluta n_i = nombre d'individus amb la modalitat C_i.
$\sum_{i=1}^{k} n_i = n$

Freqüència relativa $f_i = \dfrac{n_i}{n}$ (proporció).
$0 \le f_i \le 1$, $\sum_{i=1}^{k} f_i = 1$. En %: $100\, f_i$.

Per què la relativa? Permet **comparar mostres de mida diferent**: 52 dones de 76 i 30 de 40 no es poden comparar directament; 68,4 % i 75 % sí.

Gènere	n_i	f_i	%
Dona (F)	52	0,6842	68,42 %
Home (M)	24	0,3158	31,58 %
Total	**76**	**1**	**100 %**

Càlcul: $f_F = 52/76 = 0{,}6842$.

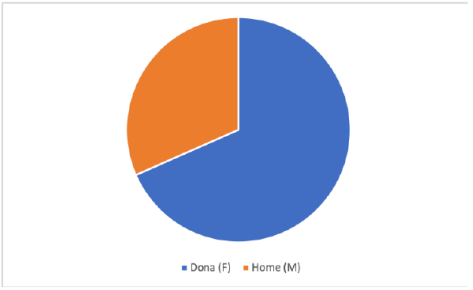


Diagrama de sectors: angle de cada sector = $360° \cdot f_i$ (dones: $246°$).

Gràfics per a qualitatives

- **Diagrama de sectors**: bo per veure parts d'un tot amb poques modalitats.
- **Diagrama de barres**: alçada = freqüència; barres **separades** (no hi ha continuïtat). Millor que els sectors quan hi ha moltes modalitats o volem comparar.
- **Pictogrames**: dibuixos proporcionals (divulgació).

Taules de contingència (dues variables qualitatives)

Taula de doble entrada: n_{ij} = nombre d'individus que tenen **alhora** la modalitat A_i i la B_j.

	B_1	$\cdots$	B_ℓ	**Total**
A_1	n_{11}	$\cdots$	$n_{1\ell}$	$n_{1\cdot}$
$\vdots$	$\vdots$		$\vdots$	$\vdots$
A_k	n_{k1}	$\cdots$	$n_{k\ell}$	$n_{k\cdot}$
Total	$n_{\cdot 1}$	$\cdots$	$n_{\cdot \ell}$	n

- **Marginals** (totals dels marges):
  de A: $n_{i\cdot} = \sum_j n_{ij}$ (marge dret)
  de B: $n_{\cdot j} = \sum_i n_{ij}$ (marge inferior)
- El punt «·» vol dir «sumat sobre aquest índex».
- **Condicionades**: dividir per un total de fila o columna, p. ex. $n_{ij}/n_{i\cdot}$ = proporció de B_j *dins* del grup A_i.

Exemple (il·lustratiu) 76 alumnes classificats per gènere i per si aproven (nota ≥ 5):

	Aprova	Suspèn	Total
Dona	38	14	52
Home	15	9	24
Total	53	23	76

Condicionades: aproven $38/52 = 73\,\%$ de les dones i $15/24 = 62{,}5\,\%$ dels homes. Si aquests percentatges fossin iguals, diríem que les dues variables són **independents**.

3 · Variables quantitatives discretes

Igual que les qualitatives, però ara els valors tenen **ordre** i es poden sumar ⇒ apareix la **freqüència acumulada**.

Freqüència acumulada $N_i = n_1 + \cdots + n_i$ (quants individus tenen un valor $\leq x_i$); relativa acumulada $F_i = N_i/n$. L'última sempre és n (o 1).

Edat	n_i	f_i	N_i	F_i
18	46	0,6053	46	0,6053
19	21	0,2763	67	0,8816
20	8	0,1053	75	0,9868
21	0	0,0000	75	0,9868
22	1	0,0132	76	1
Total	**76**	**1**		

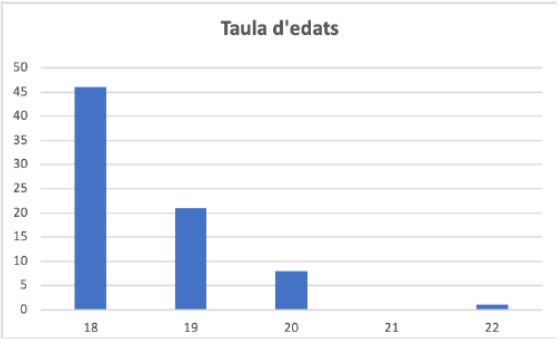


Diagrama de barres de l'edat (barres separades: valors aïllats).

Lectura ràpida El 88 % té 19 anys o menys ($F = 0{,}8816$). Moda = 18. Mediana: la posició central (38a-39a dada) cau dins del 18 ($N = 46$) ⇒ $M = 18$. Mitjana: $\bar{x} = (18 \cdot 46 + 19 \cdot 21 + 20 \cdot 8 + 22)/76 = 18{,}54$.

Nota A la presentació aquestes diapositives porten per títol «variables qualitatives», però l'edat és **quantitativa discreta**.

4 · Variables contínues: histogrames

Una variable contínua pot prendre gairebé tants valors diferents com dades ⇒ una taula «valor per valor» no resumeix res. Solució: **agrupar en intervals (classes)**.

Procediment pas a pas

① **Rang**: $R = x_{\max} - x_{\min}$.
② **Nombre de classes** k (orientatiu):

$$k \approx \sqrt{n} \ \ (n \le 100), \qquad k \approx 1 + \log_2 n = 1 + \frac{\log n}{\log 2} \ \ (n > 100, \text{ regla de Sturges})$$

③ **Amplada**: $h \approx R/k$ (s'arrodoneix a un valor còmode). Alternatives: Scott $h = 3{,}5\, s/\sqrt[3]{n}$; Freedman–Diaconis $h = 2\,\mathrm{IQ}/\sqrt[3]{n}$ (més robusta).
④ **Límits**: $[L_0, L_1), [L_1, L_2), \ldots$ amb L_0 una mica per sota del mínim. Intervals **tancats a l'esquerra i oberts a la dreta** perquè cada dada caigui en una sola classe.
⑤ **Marca de classe**: punt mitjà $x_i = \dfrac{L_{i-1} + L_i}{2}$. Representa totes les dades de la classe.
⑥ **Taula de freqüències** i ⑦ **histograma**: rectangles **enganxats** d'**àrea** proporcional a la freqüència.

Àrea, no alçada! Si totes les classes tenen la mateixa amplada, alçada ∝ freqüència. Si les amplades són diferents, cal dibuixar l'alçada com a **densitat** f_i/h_i; si no, les classes amples semblen més importants del que són.

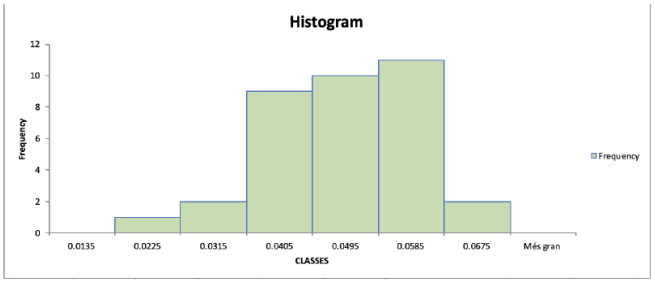
Massa poques o massa classes Poques ⇒ s'amaga la forma; massa ⇒ histograma «dentat» i sorollós. Les regles anteriors són un punt de partida.

Exemple resolt: cadmi a l'aire

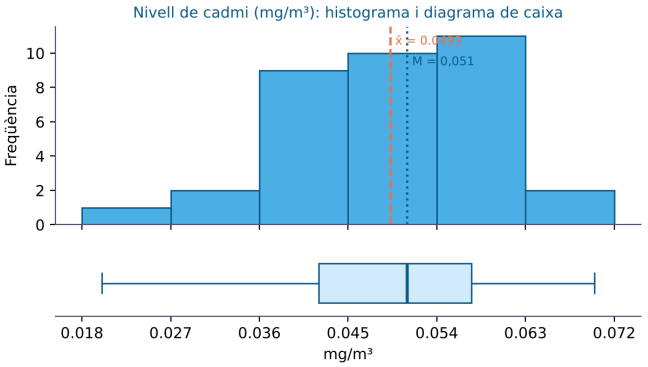
[Exercici 1.3(8) de Milton] 35 lectures de cadmi (mg/m³): 0,044 0,030 0,020 0,066 0,040 0,045 0,057 0,050 0,055 0,052 0,044 0,052 0,049 0,039 0,039 0,056 0,061 0,062 0,046 0,030 0,039 0,042 0,070 0,060 0,051 0,061 0,061 0,058 0,053 0,054 0,042 0,051 0,037 0,062 0,047.

- $x_{\min} = 0{,}020$, $x_{\max} = 0{,}070 \Rightarrow R = 0{,}050$.
- $n = 35 \le 100 \Rightarrow k \approx \sqrt{35} \approx 5{,}9 \Rightarrow$ **6 classes**. $h \approx 0{,}050/6 = 0{,}0083 \Rightarrow$ arrodonim a $h = 0{,}009$.
- $L_0 = 0{,}018$ (un poc per sota del mínim) $\Rightarrow L_6 = 0{,}018 + 6 \cdot 0{,}009 = 0{,}072 > x_{\max}$ ✓.

Classe	Marca x_i	n_i	f_i	F_i (acum.)
[0,018 ; 0,027)	0,0225	1	0,0286	0,0286
[0,027 ; 0,036)	0,0315	2	0,0571	0,0857
[0,036 ; 0,045)	0,0405	9	0,2571	0,3429
[0,045 ; 0,054)	0,0495	10	0,2857	0,6286
[0,054 ; 0,063)	0,0585	11	0,3143	0,9429
[0,063 ; 0,072)	0,0675	2	0,0571	1
Total		**35**	**1**	



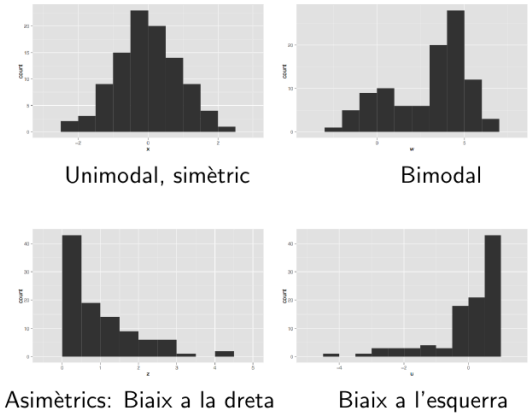
Histograma de la presentació (Excel, eix amb les marques de classe).



El mateix histograma amb la mitjana, la mediana i el diagrama de caixa.

Interpretació: la majoria de lectures estan entre 0,036 i 0,063; la distribució té una lleugera **cua a l'esquerra** (valors baixos poc freqüents), per això la mitjana (0,0493) queda per sota de la mediana (0,051).

Forma de l'histograma



- **Unimodal simètric**: un sol pic, les dues meitats s'assemblen (típic de soroll de mesura).
- **Bimodal**: dos pics ⇒ sovint hi ha **dues poblacions barrejades** (dos torns, dues màquines, dos proveïdors...). Cal separar-les!
- **Biaix a la dreta** (asimetria positiva): cua llarga cap als valors grans (ingressos, mida de partícules, temps d'espera).
- **Biaix a l'esquerra** (asimetria negativa): cua cap als valors petits (p. ex. purities properes al 100 %).

5 · Mesures de tendència central

Responen a: *al voltant de quin valor se situen les dades?*

Mitjana

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + \cdots + x_n}{n}$$

És el «centre de gravetat» de les dades: $\sum(x_i - \bar{x}) = 0$. **Sensible als valors extrems** (no robusta).

Amb dades agrupades (marques x_i, freqüències n_i): $\bar{x} \approx \frac{1}{n}\sum_{i=1}^{k} n_i x_i$.

Mediana M Valor que deixa el 50 % de les dades per sota i el 50 % per sobre.

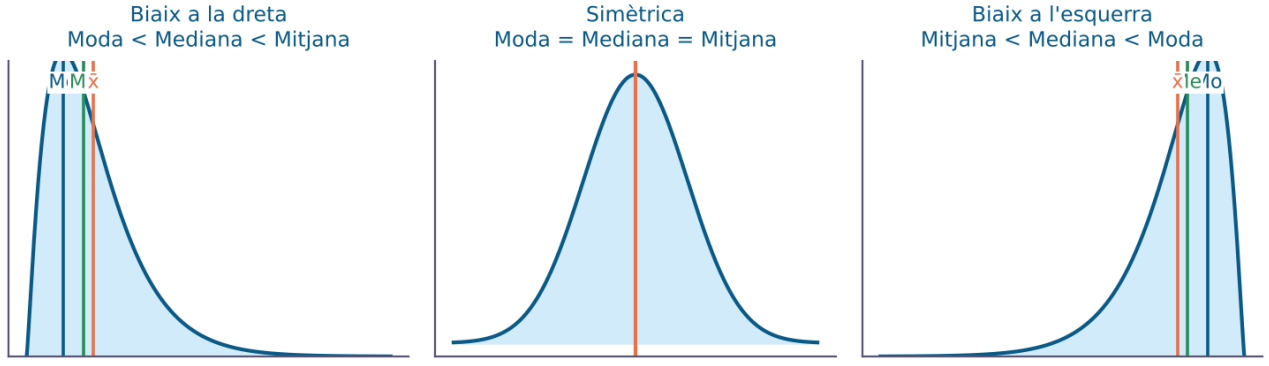
1. Ordenar les dades de menor a major.
2. n senar ⇒ la dada de posició $\frac{n+1}{2}$.
3. n parell ⇒ mitjana de les dades de posicions $\frac{n}{2}$ i $\frac{n}{2}+1$.

Robusta: gairebé no l'afecten els valors extrems.

Moda Valor (o classe) més freqüent. Pot no ser única (bimodal…). És l'única mesura de centre que té sentit per a variables **nominals**.

Exemples de mediana (de la presentació)

- 13.5, 17.8, **19.6**, 21.1, 27.2 $(n = 5)$ ⇒ $M = 19{,}6$ (posició 3).
- 13.5, 17.8, **19.6, 21.1**, 27.2, 29.5 $(n = 6)$ ⇒ $M = \frac{19{,}6+21{,}1}{2} = 20{,}35$.
- 13.5, 17.8, **19.6**, 21.1, 272 ⇒ $M = 19{,}6$ però $\bar{x} = \frac{344}{5} = 68{,}8$. Un sol valor erroni (272 en lloc de 27,2?) dispara la mitjana i deixa intacta la mediana.



La mitjana «persegueix» la cua: en distribucions asimètriques la mitjana i la mediana se separen.

Quina faig servir? Simètrica i sense atípics ⇒ **mitjana** (aprofita tota la informació). Asimètrica o amb atípics ⇒ **mediana**. Nominal ⇒ **moda**. Si $\bar{x} \gg M$: biaix a la dreta; si $\bar{x} \ll M$: biaix a l'esquerra.

Cadmi $\bar{x} = 1{,}725/35 = 0{,}0493$; mediana = dada 18a ordenada = 0,051; moda: 0,039 i 0,061 (3 cops cadascuna, bimodal en valors exactes); classe modal: [0,054 ; 0,063). Amb les marques de classe: $\bar{x} \approx 1{,}7235/35 = 0{,}0492$ (gairebé igual).

6 · Mesures de dispersió i de posició

Dues mostres poden tenir la mateixa mitjana i ser molt diferents: cal mesurar **com d'escampades** estan les dades.

Variància mostral

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1} = \frac{n\sum x_i^2 - (\sum x_i)^2}{n(n-1)}$$

Mitjana (corregida) dels quadrats de les desviacions respecte de $\bar{x}$. Unitats al **quadrat** (mg²/m⁶!).

La segona fórmula és la «de càlcul»: només cal $\sum x_i$ i $\sum x_i^2$.

Per què $n-1$? Les desviacions $x_i - \bar{x}$ sumen 0, de manera que només $n-1$ són «lliures» (graus de llibertat). Dividir per $n-1$ fa que s^2 no subestimi, de mitjana, la variància de la població. Les calculadores ho indiquen com s, σ_{n-1} o S_x; R sempre usa $n-1$.

Desviació típica $s = +\sqrt{s^2}$. Mateixes **unitats** que les dades ⇒ és la més interpretable («distància típica a la mitjana»).

Coeficient de variació $CV = \frac{s}{\bar{x}}$ (sovint en %). **Adimensional** ⇒ compara la dispersió de variables amb unitats o escales diferents. Només té sentit si $\bar{x} > 0$.

Cadmi ($n = 35$) $\sum x_i = 1{,}725$, $\sum x_i^2 = 0{,}089199$.

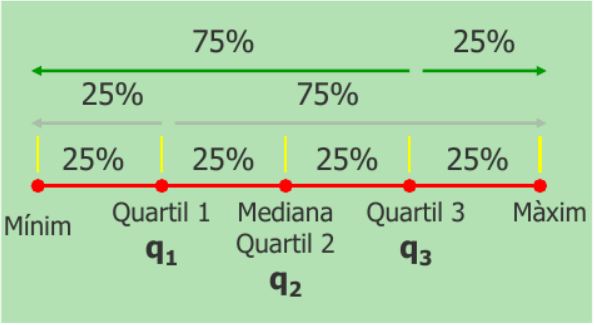
$$s^2 = \frac{35 \cdot 0{,}089199 - 1{,}725^2}{35 \cdot 34} = \frac{3{,}121965 - 2{,}975625}{1190} = 0{,}000122975$$

$s = \sqrt{0{,}000122975} = 0{,}0111$ mg/m³, $CV = 0{,}0111/0{,}0493 = 0{,}225$ ⇒ **22,5 %**.

Mesures de posició: quartils

- Q_1: deixa el **25 %** de les dades per sota.
- $Q_2 = M$: la mediana (50 %).
- Q_3: deixa el **75 %** per sota.
- **Percentil** p: deixa el $p\,\%$ per sota ($Q_1 = P_{25}$, $Q_3 = P_{75}$).

Càlcul a mà: Q_1 ≈ mediana de la meitat inferior, Q_3 ≈ mediana de la meitat superior. Hi ha diversos convenis i petites diferències són normals (R per defecte interpola: `quantile()`).



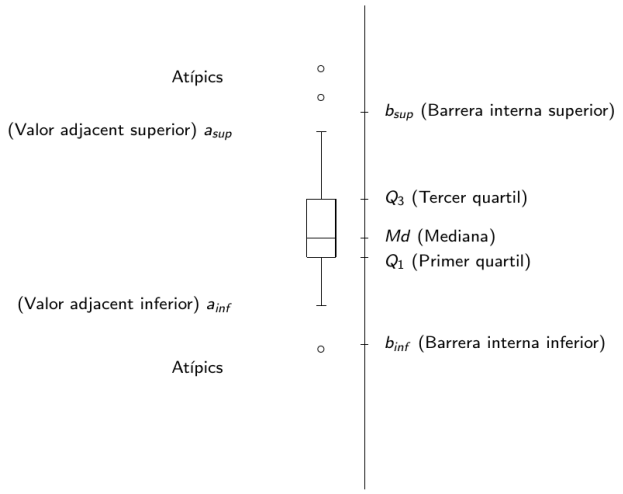
Rang $R = x_{\max} - x_{\min}$. Fàcil, però depèn només de 2 dades ⇒ **molt sensible als atípics**.

Rang interquartílic $RI = Q_3 - Q_1$: amplada del 50 % central. **Robust**. És l'«equivalent» robust de s.

Cadmi $Q_1 = 0{,}042$, $M = 0{,}051$, $Q_3 = 0{,}0575$ ⇒ $RI = 0{,}0155$; $R = 0{,}070 - 0{,}020 = 0{,}050$.

7 · Diagrames de caixa (box-plot)

Resum gràfic de 5 nombres (mín., Q_1, M, Q_3, màx.) que a més **detecta atípics**.

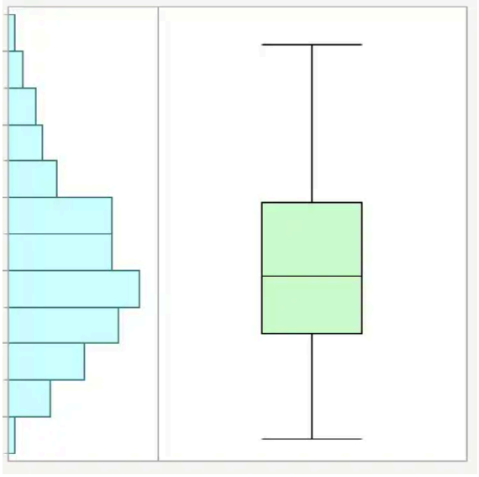


Elements del diagrama de caixa (presentació).

- **Caixa**: de Q_1 a Q_3 (conté el 50 % central); la ratlla interior és la mediana.
- **Barreres** (no es dibuixen):
  $b_{inf} = Q_1 - 1{,}5\,RI,\ \ b_{sup} = Q_3 + 1{,}5\,RI$
- **Bigotis**: fins als **valors adjacents**, és a dir, la dada més extrema que encara és *dins* de les barreres:
  $a_{inf} = \min\{x : x \geq b_{inf}\}$, $a_{sup} = \max\{x : x \leq b_{sup}\}$.
- **Atípics** (outliers): dades fora de les barreres, es marquen amb punts ○.

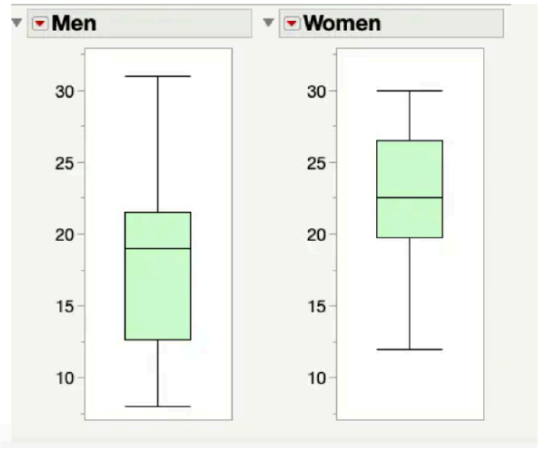
Cadmi pas a pas $1{,}5\,RI = 1{,}5 \cdot 0{,}0155 = 0{,}02325$.
$b_{inf} = 0{,}042 - 0{,}02325 = 0{,}01875;\ \ b_{sup} = 0{,}0575 + 0{,}02325 = 0{,}08075$.
Totes les dades són dins $[0{,}01875;\ 0{,}08075]$ ⇒ **cap atípic**; bigotis de 0,020 a 0,070. El bigoti inferior més llarg i la mediana desplaçada cap a Q_3 confirmen un lleu biaix a l'esquerra (veure figura de la pàg. de l'histograma).

Com es llegeix un box-plot



Histograma (girat) i box-plot de les mateixes dades.

- **Posició** de la mediana ⇒ centre.
- **Alçada de la caixa** (RI) i longitud dels bigotis ⇒ dispersió.
- **Asimetria**: mediana descentrada dins la caixa i bigotis de longitud diferent.
- Són ideals per **comparar grups** posats l'un al costat de l'altre.



Comparació de dos grups (presentació).

Interpretació (que no fa la presentació)

- Mediana: dones ≈ 22,5 > homes ≈ 19 ⇒ valors típicament més alts en dones.
- Caixa dels homes més alta (≈ 12,5–21,5) que la de les dones (≈ 20–26,5) ⇒ els homes són **més dispersos**.
- Dones: bigoti inferior llarg ⇒ asimetria cap a valors baixos.
- Cap dels dos grups mostra atípics.

A l'exemple anterior de la presentació (eix 50–250), la mediana (≈120) està enganxada a Q_1 (≈110) i lluny de Q_3 (≈198) ⇒ fort **biaix a la dreta**.

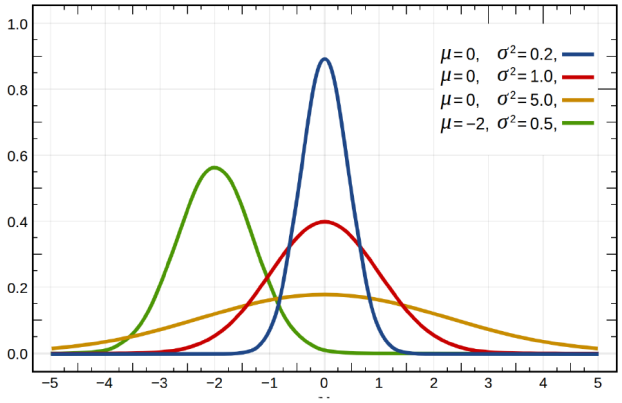
8 · La distribució normal (campana de Gauss)

Molts fenòmens (errors de mesura, propietats d'un producte fabricat…) donen histogrames **acampanats i simètrics**. El model matemàtic idealitzat d'aquest histograma és la distribució normal.

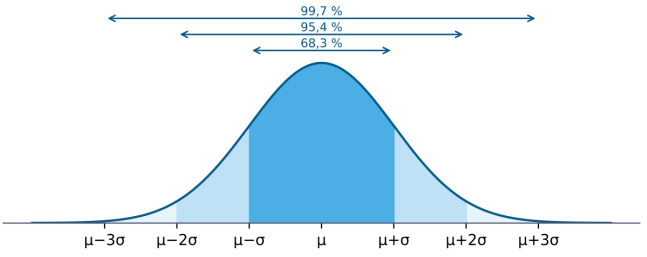
$N(\mu, \sigma^2)$ Funció de densitat:

$$f(x) = \frac{1}{\sqrt{2\pi}\,\sigma} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right), \qquad x \in \mathbb{R}$$

- μ = centre (mitjana = mediana = moda), anàleg poblacional de $\bar{x}$.
- σ = amplada de la campana, anàleg poblacional de s. Punts d'inflexió a $\mu \pm \sigma$.
- L'**àrea** sota la corba entre a i b = proporció de dades esperada entre a i b. Àrea total = 1.



Canviar μ desplaça la corba; augmentar σ^2 l'aplana i l'eixampla.



Regla empírica 68–95–99,7.

Regla empírica En dades aproximadament normals: ≈ **68 %** a $\bar{x} \pm s$, ≈ **95 %** a $\bar{x} \pm 2s$, ≈ **99,7 %** a $\bar{x} \pm 3s$. Una dada a més de $3s$ de la mitjana és molt rara ⇒ sospitosa (base dels gràfics de control de qualitat).

Normal estàndard i tipificació $N(0,1)$: $f(z) = \frac{1}{\sqrt{2\pi}} e^{-z^2/2}$. Qualsevol normal es transforma en estàndard amb

$$z = \frac{x-\mu}{\sigma} \quad \text{(«a quantes desviacions típiques està } x \text{ de la mitjana»)}$$

Càlculs amb R

- `pnorm(x, m, s)` = $P(X \leq x)$ = àrea a l'**esquerra** de x.
- `qnorm(p, m, s)` = valor x que deixa una àrea p a l'esquerra (funció inversa, percentil).
- Àrea a la dreta: `1 - pnorm(x,m,s)`; entre a i b: `pnorm(b,m,s) - pnorm(a,m,s)`.

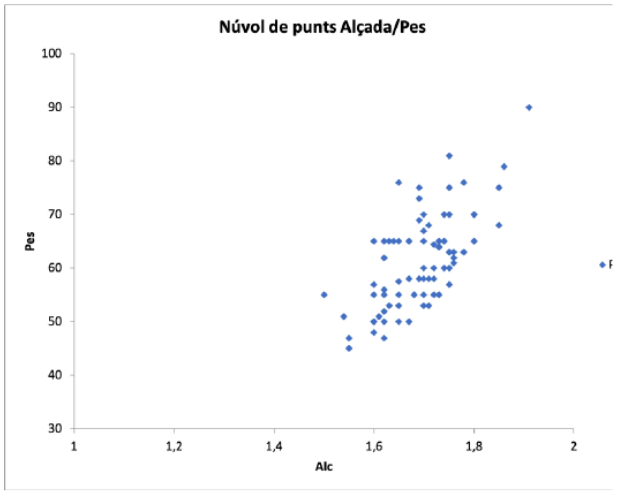
Exemple $X \sim N(73,\, 4^2)$.
• $P(X < 70)$: $z = \frac{70-73}{4} = -0{,}75$ ⇒ `pnorm(70,73,4)` = 0,2266 ⇒ el **22,7 %** està per sota de 70.
• Valor que deixa el 90 % per sota: `qnorm(0.9,73,4)` = 78,13 $(= 73 + 1{,}2816 \cdot 4)$.
• Extra: $P(65 < X < 81) = P(-2 < Z < 2)$ = `pnorm(81,73,4)-pnorm(65,73,4)` = 0,954 (regla del 95 %).

Nota històrica: la corba normal ja apareix amb De Moivre (1733); Gauss la va fer servir el 1809 per justificar el mètode dels mínims quadrats, i per això porta el seu nom.

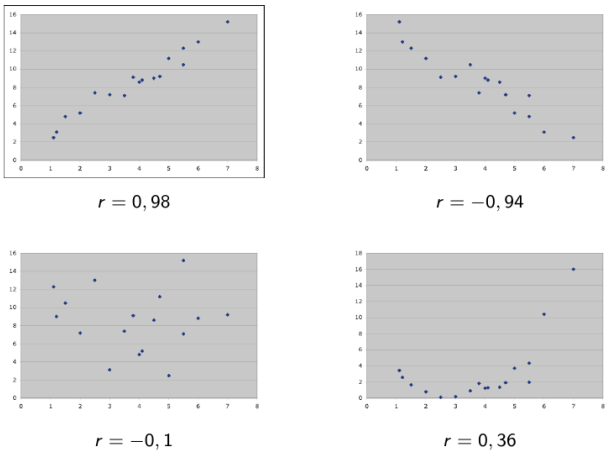
9 · Dues variables quantitatives

Per a cada individu tenim un parell (x_i, y_i). Objectiu: veure si X i Y estan **relacionades** i, si ho estan linealment, **predir** Y a partir de X.

Núvol de punts (diagrama de dispersió)



Pes vs alçada de 76 alumnes.



Directa, inversa, sense relació i no lineal.

Sempre mirar el núvol abans de calcular res: ens diu si la relació és lineal, si hi ha atípics o grups.

Covariància

$$S_{XY} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{n(n-1)}$$

Idea: dividim el pla en 4 quadrants amb centre $(\bar{x}, \bar{y})$. Si la majoria de punts són als quadrants «dalt-dreta» i «baix-esquerra», els productes són positius ⇒ $S_{XY} > 0$ (relació **directa**). Si són als altres dos ⇒ $S_{XY} < 0$ (**inversa**). Si estan repartits ⇒ $S_{XY} \approx 0$.

Limitacions 1) Té unitats (kg·m) i depèn de l'escala: si passem l'alçada de m a cm, S_{XY} es multiplica per 100 ⇒ **no diu si la relació és forta**. 2) Independents ⇒ $S_{XY} \approx 0$, però **no al revés**: $S_{XY} \approx 0$ pot amagar una relació no lineal (paràbola).

Coeficient de correlació de Pearson

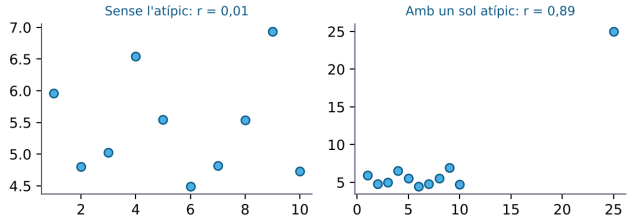
$$r_{XY} = \frac{S_{XY}}{S_X\, S_Y}, \qquad -1 \le r \le 1$$

Covariància «normalitzada»: **sense unitats**. Mesura només la força de la relació **lineal**.

$\lvert r\rvert$	Interpretació (orientativa)
$= 1$	tots els punts sobre una recta
0,9 – 1	correlació lineal forta (signe = sentit)
0,5 – 0,9	moderada
0 – 0,5	feble
≈ 0	no hi ha relació lineal (potser n'hi ha una de no lineal)

Valors dels 4 gràfics anteriors: $r = 0{,}98$; $-0{,}94$; $-0{,}1$; $0{,}36$ (aquest últim és una paràbola clara: relació forta però **no lineal** ⇒ r baix!).

Coeficient de determinació $R^2 = r^2 \in [0, 1]$: proporció de la variabilitat de Y que **explica** la recta de regressió.



Un únic punt atípic pot crear una correlació alta on no n'hi ha.

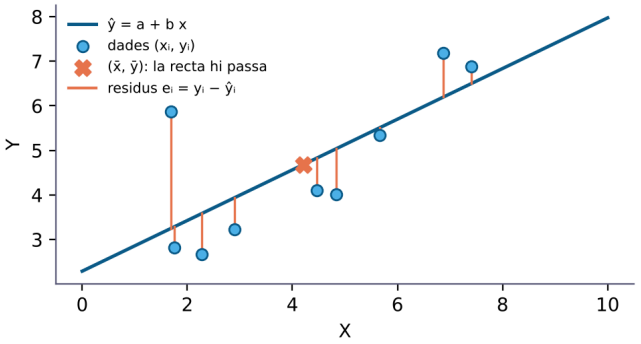
Correlació ≠ causalitat Una r alta no demostra que X causi Y: pot haver-hi una tercera variable (p. ex. temperatura ambient) que afecti totes dues.

Recta de regressió (mínims quadrats)

Busquem la recta $\hat{y} = a + bx$ que fa **mínima la suma dels quadrats dels residus** (distàncies **verticals**):

$$\min_{a,b} \sum_{i=1}^{n} \left(y_i - (a + bx_i)\right)^2$$

$$b = \frac{S_{XY}}{S_X^2} = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{n\sum x_i^2 - \left(\sum x_i\right)^2}, \qquad a = \bar{y} - b\,\bar{x}$$



Residus (verticals) i el punt mitjà $(\bar{x}, \bar{y})$.

- **Pendent** b: quant canvia $\hat{y}$, en mitjana, quan x augmenta 1 unitat. Mateix signe que S_{XY} i que r. També $b = r\,\frac{S_Y}{S_X}$.
- **Ordenada a l'origen** a: valor de $\hat{y}$ quan $x = 0$ (sovint sense sentit físic).
- La recta **sempre passa per** $(\bar{x}, \bar{y})$.
- **Predicció**: $\hat{y} = a + bx$ (valor esperat de Y per a $X = x$).
- **Residu**: $e_i = y_i - \hat{y}_i$ (observat − predit). Positiu ⇒ el punt queda per sobre de la recta. Els residus sumen 0.

Compte • **No extrapolar**: la recta només és fiable dins del rang de x observat. • La recta de Y sobre X **no** és la mateixa que la de X sobre Y. • Mirar sempre el núvol: si la relació no és lineal, la recta no serveix.

Per organitzar els càlculs a mà: taula amb columnes X, Y, X^2, Y^2, XY i fila de totals.

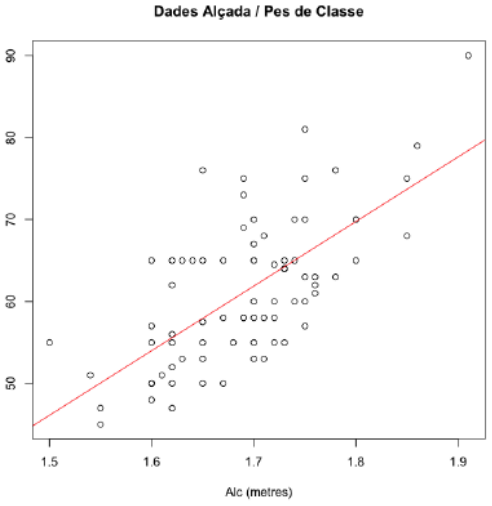
Exemple complet: pes (Y) en funció de l'alçada (X), $n = 76$

$\sum x$	$\sum y$	$\sum x^2$	$\sum y^2$	$\sum xy$
128,49	4647,00	217,69	290187,50	7892,14

① Mitjanes: $\bar{x} = 128{,}49/76 = 1{,}6907$ m, $\bar{y} = 4647/76 = 61{,}145$ kg.
② Covariància: $S_{XY} = \dfrac{76 \cdot 7892{,}14 - 128{,}49 \cdot 4647}{76 \cdot 75} = \dfrac{2709{,}6}{5700} = 0{,}4753$ kg·m.
③ Desviacions típiques: $S_X = 0{,}0777$ m $(S_X^2 = 0{,}00604)$, $S_Y = 8{,}98$ kg.
④ Correlació: $r = \dfrac{0{,}4753}{0{,}0777 \cdot 8{,}9799} = 0{,}68$ ⇒ relació lineal **directa moderada**. $R^2 = 0{,}68^2 = 0{,}46$: l'alçada explica el **46 %** de la variabilitat del pes.
⑤ Recta: $b = 0{,}4753/0{,}006037 = 78{,}79$ kg/m, $a = 61{,}145 - 78{,}79 \cdot 1{,}6907 = -72{,}05$ kg.

$$\widehat{\text{Pes}} = -72{,}05 + 78{,}79 \cdot \text{Alç}$$

⑥ Interpretació: cada **cm** més d'alçada suposa, en mitjana, **0,79 kg** més. $a = -72$ kg no té sentit físic (alçada 0 fora del rang).
⑦ Predicció per a 1,80 m: $\hat{y} = -72{,}05 + 78{,}79 \cdot 1{,}80 = 69{,}8$ kg. Si un alumne d'1,80 m pesa 65 kg, el seu residu és $65 - 69{,}8 = -4{,}8$ kg.



Núvol de punts amb la recta de regressió (R).

10 · Resum d'R

```r
# Importar dades (RStudio: Environment → Import Dataset) i triar una columna
cd <- Cadmi$Cd
mean(cd); median(cd)        # mitjana, mediana
var(cd);  sd(cd)            # variància i desviació típica (amb n-1)
sd(cd)/mean(cd)             # coeficient de variació
range(cd); diff(range(cd))  # mínim-màxim i rang
quantile(cd); IQR(cd)       # quartils i rang interquartílic
summary(cd)                 # mín, Q1, mediana, mitjana, Q3, màx
table(classe$Gen)           # freqüències absolutes
prop.table(table(classe$Gen))   # freqüències relatives
table(classe$Gen, classe$Comarca) # taula de contingència

hist(cd); boxplot(cd); barplot(table(classe$Edat)); pie(table(classe$Gen))

pnorm(70, 73, 4)            # P(X <= 70) si X ~ N(73, 4^2)  -> 0.2266
qnorm(0.9, 73, 4)           # percentil 90                  -> 78.126

alc <- classe$Alc; pes <- classe$Pes
cov(alc, pes); cor(alc, pes)            # 0.4753   0.6815
model <- lm(pes ~ alc); coef(model)     # a = -72.05, b = 78.79
summary(model)$r.squared                # R^2 = 0.464
predict(model, data.frame(alc = 1.80))  # 69.8 kg
plot(alc, pes); abline(model, col = "red")
```

Recorda R distingeix majúscules: `Classe` i `classe` són objectes diferents. Els decimals s'escriuen amb punt.

11 · Formulari

Freqüències

$f_i = \dfrac{n_i}{n} \quad \sum n_i = n,\ \sum f_i = 1$
$N_i = n_1 + \cdots + n_i, \quad F_i = N_i/n$
Marginals: $n_{i\cdot} = \sum_j n_{ij},\ n_{\cdot j} = \sum_i n_{ij}$

Histogrames

$k \approx \sqrt{n}\ (n \le 100)$; $k \approx 1 + \log_2 n$ (Sturges)
$h \approx R/k$; Scott: $h = \dfrac{3{,}5\,s}{\sqrt[3]{n}}$; F-D: $h = \dfrac{2\,RI}{\sqrt[3]{n}}$
Marca: $x_i = \frac{L_{i-1}+L_i}{2}$; densitat: f_i/h_i

Centre

$\bar{x} = \dfrac{1}{n}\sum x_i$ (agrupades: $\bar{x} \approx \frac{1}{n}\sum n_i x_i$)
Mediana: posició $\frac{n+1}{2}$ (si n parell, mitjana de les dues centrals)
Moda: valor més freqüent

Dispersió i posició

$s^2 = \dfrac{\sum(x_i-\bar{x})^2}{n-1} = \dfrac{n\sum x_i^2 - (\sum x_i)^2}{n(n-1)}$
$s = \sqrt{s^2} \qquad CV = \dfrac{s}{\bar{x}}$
$R = x_{\max} - x_{\min} \qquad RI = Q_3 - Q_1$

Box-plot

$b_{inf} = Q_1 - 1{,}5\,RI \quad b_{sup} = Q_3 + 1{,}5\,RI$
Adjacents: dades més extremes dins de les barreres
Atípic: $x < b_{inf}$ o $x > b_{sup}$

Normal

$f(x) = \dfrac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$
$z = \dfrac{x-\mu}{\sigma} \sim N(0,1)$
$\mu \pm \sigma : 68\% \quad \mu \pm 2\sigma : 95\% \quad \mu \pm 3\sigma : 99{,}7\%$
R: `pnorm(x,m,s)`, `qnorm(p,m,s)`

Dues variables

$S_X^2 = \dfrac{n\sum x_i^2 - (\sum x_i)^2}{n(n-1)}$
$S_{XY} = \dfrac{\sum(x_i-\bar{x})(y_i-\bar{y})}{n-1} = \dfrac{n\sum x_i y_i - \sum x_i \sum y_i}{n(n-1)}$

$r_{XY} = \dfrac{S_{XY}}{S_X S_Y} = \dfrac{n\sum x_i y_i - \sum x_i \sum y_i}{\sqrt{[n\sum x_i^2 - (\sum x_i)^2]\,[n\sum y_i^2 - (\sum y_i)^2]}}$
$-1 \le r \le 1 \qquad R^2 = r^2$

Regressió $\hat{y} = a + bx$

$b = \dfrac{S_{XY}}{S_X^2} = r\dfrac{S_Y}{S_X} \qquad a = \bar{y} - b\,\bar{x}$
Predicció: $\hat{y} = a + bx$
Residu: $e_i = y_i - \hat{y}_i,\ \sum e_i = 0$

Interpretació de $|r|$

0,9–1 forta · 0,5–0,9 moderada · 0–0,5 feble · ≈0 sense relació *lineal*

Quina mesura?

Simètrica: $\bar{x}$ i s · Asimètrica / atípics: M i RI · Nominal: moda i freqüències · Comparar dispersions amb unitats diferents: CV

12 · Annex: valoració de la presentació

Punts forts

- Estructura lògica i completa del temari bàsic: tipus de variables → taules → gràfics → centre → dispersió → normal → regressió.
- Bona notació formal (taules genèriques amb n_i, f_i, marginals).
- Exemples amb dades reals i propers a l'enginyeria (cadmi) i a l'alumnat (pes/alçada).
- Inclou el codi R i el resultat, cosa molt útil per a les pràctiques.
- Bones imatges per a la forma dels histogrames, el box-plot i els valors de r.

Punts a millorar

- Molt esquemàtica: moltes fórmules sense explicar *per què* (p. ex. el $n-1$, l'àrea vs alçada a l'histograma, el significat de la covariància).
- Falten **interpretacions**: els box-plots de «Exemple» i «Un altre exemple» no tenen context ni conclusions; no s'interpreta el pendent ni l'R^2.
- No calcula els quartils ni el box-plot de cap exemple, ni explica com es calculen els quartils.
- No presenta la freqüència acumulada fins a l'exemple del cadmi, i el polígon de freqüències/ogiva no apareixen.
- Barreja de convencions: decimals amb punt i amb coma; S i s; títols erronis (discretes sota «qualitatives»).
- Alguns gràfics són captures d'Excel/castellà («Curva de regresión ajustada», «Frecuencia», «Més gran»).
- Inconsistència de dades: la taula de notes suma 75 i la mostra té 76 alumnes (no s'explica la dada que falta).

Nota global orientativa: 6,5/10. Correcta com a guió de classe (pensada per acompanyar l'explicació oral), però insuficient per estudiar-hi sola: per això aquests apunts afegeixen explicacions, interpretacions i exemples resolts.

Errades ortogràfiques, gramaticals i de contingut

Diap.	Diu	Hauria de dir	Tipus
4	(üs de paquets estadístics (R)	(ús de paquets estadístics, R) — accent i parèntesi sense tancar	Ortografia
5	examen final de la l'assignatura	examen final de l'assignatura	Gramàtica
6	interés	interès	Ortografia
7	els seu valors modalitats	els seus valors, modalitats	Gramàtica
7	un nóm	un nom	Ortografia
7	relació de ordre	relació d'ordre	Ortografia (apostrofació)
7	volume	volum	Ortografia
12, 16	Títol «Descripció de variables qualitatives»	«…quantitatives discretes» (l'edat és quantitativa)	Contingut
18	subintervals en que subdividim	subintervals en què subdividim	Ortografia
19	Altres regles … inclou	Altres regles … inclouen	Concordança
19	Llei d'Sturges	Regla de Sturges (és una regla empírica, no una llei)	Terminologia
23	$x_{max} = 0{,}02$ i $x_{max} = 0{,}07$	$x_{min} = 0{,}02$ i $x_{max} = 0{,}07$	Contingut
26	Es pot influir fàcilment per valors extrems	Es veu fàcilment influïda pels valors extrems	Gramàtica
26	Es tracta del valors més habitual	Es tracta del valor més habitual	Concordança
30, 55	l'anomenen Cadmi / Classe	l'anomenem	Ortografia
30	"Environment→Import Dataset"(finestra … Rstudio)	espai abans del parèntesi; «RStudio»	Tipografia
32	Gauss va descobrir la distribució normal en 1809	…el 1809; a més, ja l'havia introduïda De Moivre (1733)	Gramàtica / contingut
33	σ correspond a S	σ correspon a S	Ortografia
34	**Distribució normal: diferentes parámetros**	Distribució normal: diferents paràmetres (està en castellà)	Ortografia
36	deixa per sota al 25%	deixa per sota el 25 %	Gramàtica
39	Barreres inferior … i superior	Barrera inferior … i superior	Concordança
47	Si no tenen relació, són independents, aleshores la covariància aproximarà el zero	Si són independents, la covariància serà propera a zero (el recíproc no és cert)	Contingut / redacció
50	teniem	teníem	Ortografia
51	minimitza les distàncies	minimitza la suma dels quadrats de les distàncies verticals	Precisió
52	és calcula	es calcula	Ortografia
53	la diferencia	la diferència	Ortografia
54	per les dades	per a les dades	Gramàtica
54	$76 \cdot 7892{,}14 - 128{,}49 \cdot 4672$	$\cdots \cdot 4647$ (el total de Y és 4647; amb 4672 surt negatiu)	Contingut (errata)
56	Calculem la recta de regressió les variables	…la recta de regressió **de** les variables	Gramàtica
56	$b = 0{,}4753/0{,}0060 = 78{,}7853$	Amb 0,0060 surt 79,2: cal $S_X^2 = 0{,}006037$	Arrodoniment
57	en funció de Alc	en funció d'Alc	Apostrofació
4	Gràfics «Curva de regresión ajustada», «Frecuencia»	Etiquetes en castellà	Idioma

Els càlculs numèrics de la presentació (taula de freqüències del cadmi, mitjana, variància, r, recta, `pnorm`, `qnorm`) s'han comprovat i són correctes llevat dels punts indicats.